ADR-001: Arquitectura multiagente con supervisor y escalamiento determinista para incidentes de pagos

- **Estado:** Aceptado
- **Fecha:** 2026-10-25
- **Autor:** Aldair Bernal Betancur
- **Evidencia:** `01_RETO_Estudiante_Arquitectura_Pagos.ipynb`, ejecutado con Groq (`openai/gpt-oss-120b`, `temperature=0`)

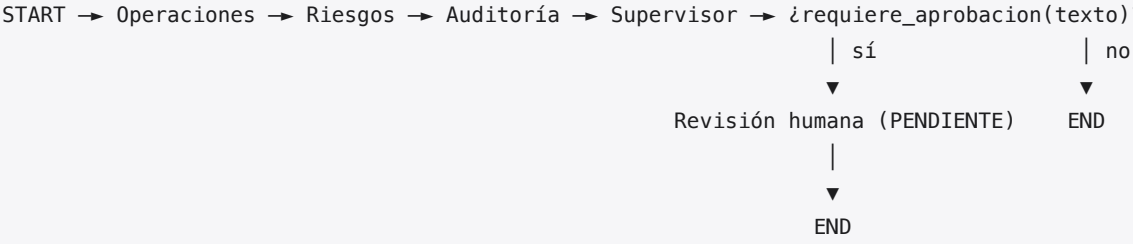
Contexto

Un sistema de pagos presenta 18 % de transacciones fallidas durante 25 minutos, sin evidencia confirmada de filtración y con mantenimiento en seis horas. Se necesita un plan para los próximos 30 minutos con riesgos y validaciones. Los requisitos que condicionan el diseño son:

1. No inventar causa raíz, filtración, acciones ejecutadas ni cifras.
2. Las acciones que puedan alterar pagos requieren **aprobación humana**; un error no es reversible como lo es reescribir un texto.
3. Debe poder auditarse quién propuso qué.

Decisión

Se adopta un grafo secuencial de LangGraph con **tres especialistas, un supervisor y un punto de revisión humana**. La ruta tras el supervisor la decide una **regla determinista** (`requiere_aprobacion`), no el LLM.



- **Operaciones** propone medidas reversibles; **Riesgos** evalúa impacto y umbrales; **Auditoría** separa hechos de hipótesis y pide validaciones.
- **Supervisor** integra el plan con responsables por rol. Es el único que escribe `decision` y `requiere_revision`.
- **Revisión humana** es un marcador simulado: escribe `PENDIENTE` y nunca aprueba. Una aprobación real requeriría `interrupt()` y un checkpointer.
- Cada nodo escribe solo su campo y agrega su nombre a `bitacora`, que registra la ruta real.

Alternativas consideradas

Alternativa	Llamadas LLM	Latencia media (n = 3)	Ventajas	Inconvenientes
A. Un solo agente (baseline)	1	3.77 s (desv. 0.58)	Más simple, rápida y barata	Sin trazabilidad por rol; sin separación explícita de hechos e hipótesis; el control depende del prompt
B. Un especialista + supervisor	2	7.06 s (desv. 1.78)	Mismo control de escalamiento (3 de 3 ejecuciones a revisión humana) con la mitad de las llamadas	Sin evaluación de riesgos ni auditoría de hechos separadas
C. Tres especialistas + supervisor (elegida)	4	21.38 s (desv. 1.01)	Trazabilidad por rol; la auditoría expone hechos, hipótesis y datos faltantes	≈5.7× la latencia y 4× las llamadas del baseline; más complejidad

Alternativa	Llamadas LLM	Latencia media (n = 3)	Ventajas	Inconvenientes
D. Escalamiento decidido por el LLM	igual que C	igual que C	Más flexible ante verbos no previstos	Un prompt no es una garantía: una respuesta mal formulada podría omitir la aprobación

Se descartó D por el requisito 2: el control no debe depender de que el modelo lo recuerde. La paralelización de los especialistas no se evaluó; reduciría la latencia pero cambia el estado compartido (cada especialista dejaría de ver las propuestas previas).

Justificación

Se elige C porque el criterio dominante es **control y trazabilidad**, y porque la auditoría produce una separación visible de hechos, hipótesis y datos faltantes que ni el baseline ni B generan de forma estructurada. La regla determinista cumple el requisito 2: en el caso de presión por una acción irreversible (D), el plan quedó retenido para revisión humana.

Esta decisión no se apoya en una mejora de calidad demostrada. La evidencia no compara la calidad del baseline con la del grafo, y B ofrece el mismo control a menor costo. C solo se justifica si el valor de la auditoría y de la evaluación de riesgos se confirma en una medición posterior.

Consecuencias

Positivas

- Ruta auditable (`bitacora`) y propuestas separadas por rol.
- Escalamiento reproducible por una regla de código y probado con autocomprobaciones sin tokens.

Negativas y riesgos observados

- **Costo:** 4 llamadas y ≈21 s por incidente, además de más cuota por minuto y más piezas que mantener.
- **Textos cortados:** todas las respuestas de los agentes y las decisiones de los casos terminaron a mitad de frase por `max_tokens`, y el modelo no respetó los límites de palabras. La regla analiza texto incompleto.
- **Cifras inventadas:** aparecieron umbrales ausentes del escenario (`>5 %`, `>200 ms`, `25 %`, `80 %`). Pydantic valida forma, no verdad.
- **Escalamiento poco informativo:** los cuatro casos pasaron por revisión humana, porque la regla no distingue "solicitar aprobación para X" de "hacer X"; riesgo de fatiga de aprobaciones. Su comportamiento varió entre ejecuciones.
- **Falsos negativos de la regla:** verbos como "detener", "desconectar", "aislar" o "redirigir" no están en la lista.
- Con n = 3 no se pueden afirmar diferencias estadísticas de latencia ni de calidad.

Acciones de seguimiento

1. Subir `max_tokens`, detectar truncamiento con `finish_reason` y salida estructurada del supervisor validada con `PropuestaEspecialista` o similar.
2. Validar por código que no aparezcan cifras ausentes del escenario.
3. Ampliar la lista de verbos de impacto y probar los falsos negativos.
4. Comparar la calidad de A, B y C con una rúbrica y más repeticiones, y revisar esta decisión con esos datos.
5. Implementar la aprobación real con `interrupt()`, checkpointer, registro de aprobador y tiempo máximo de espera (sesión 15).